

KYC Reputation Copilot — план сборки (HackYeah 2026)

Oct 2, 2026 · @Leonid

Решения и допущения

Делаем KYC Reputation Copilot для банка: пять фич на одном движке. Главный трек — Goldman Sachs AI Control Layer, если команда не решит иначе. Строим в порядке F0 → F1 → F4 → F5 → F2 → F3: сначала то, без чего демо не существует.

Решение	Что выбрали	Оговорка
Источники	Акторы Apify: новости, Google News, полный текст статей, при необходимости соцсети	Прогнать заранее и закэшировать. На сцене не зависеть от живого запуска
Хранилище	Supabase: Postgres + pgvector, Storage, Auth	В проде — self-hosted Supabase внутри периметра банка
Облачные модели	Только публичные данные: статьи, открытые реестры	Запрет на конфиденциальное — в коде роутера, не в промпте
Локальные модели	Всё, что касается клиента и банка: KYC-досье, политика, внутренние заметки	Ollama, модель класса 7-8B с JSON-выводом. Скорость замерить в первый час
Jev	Квалификация: подходит статья или нет	Допущение: Jev — шаг классификации, каскад «локально → облако, если не уверен». Если это отдельный сервис или модель, меняется только адаптер
Оценка риска	Детерминированная матрица 0-10	LLM извлекает факты, балл считает код
Решение по клиенту	Всегда человек	Система рекомендует и обосновывает

Решение	Что выбрали	Оговорка
Данные клиентов и политика	Синтетические	Реальные компании — только публичные факты, подтверждённые судом или регулятором
Язык продукта	Английский	Требование Goldman

Открытый вопрос к команде: что такое Jev — модель, сервис или человек? План ниже считает его шагом пайплайна.

Архитектура и маршрутизация моделей

Все пять фич работают на одном пайплайне. Где можно облако, а где только локальная модель, решает роутер по метке данных, а не разработчик в коде фичи.

Публичные данные могут идти в облако, данные клиента — только локально



поток данных · 2 зоны, роутер между ними

Верхняя зона работает с публичными статьями, нижняя — с данными клиента и банка. Единственный путь между ними — через роутер, и факты переходят вниз, а не досье вверх.

F0. Фундамент: общий движок

Без F0 не работает ни одна из пяти фич, поэтому первые три часа вся команда на нём. Цель к 14:00: статья из Apify проходит Jev и сохраняется с причиной, а роутер кодом отказывает в отправке конфиденциального в облако.

- 1. Репозиторий.** Monorepo: `frontend` (React + Vite), `backend` (FastAPI), `worker`.
`.env` в `.gitignore` с первой минуты, `.env.example` без значений. Ключи: Supabase, облачный LLM, токен Apify.
- 2. Supabase.** Проект, расширение pgvector, приватный bucket, два пользователя: `analyst` и `compliance`. Таблицы:
 - `entities` — компании и связанные лица;
 - `sources_raw` — сырые результаты Apify;
 - `articles` — нормализованные статьи;
 - `findings` — факты с цитатами;
 - `scores` — балл и его компоненты;
 - `policies`, `policy_clauses` — политика банка по пунктам;
 - `client_files` — KYC-досье;
 - `assessments` — итог по клиенту;
 - `memos` — брифы;
 - `audit_log` — журнал.
- 3. Локальная модель.** Ollama на самом мощном ноутбуке команды, модель 7–8B с JSON-выводом. Замерить скорость на реальном промпте в первый час. Если медленно — локально оставить только то, что обязано быть локальным (F4 и конфиденциальные части F5).
- 4. Роутер моделей.** Одна функция `llm.call(task, payload, labels)`. Метка данных (`public` / `confidential`) выбирает эндпоинт. `confidential` → только локальная модель, иначе исключение. Каждый вызов пишется в `audit_log`: задача, модель, метка, время, стоимость.
- 5. Ингест Apify.** Выбрать 2–3 актора: новостной поиск, Google News, извлечение полного текста статьи. Запуск через API Apify (синхронный запуск с получением датасета — проверить в первый час), результат → `sources_raw` → нормализация в `articles` (`url`, `title`, `text`, `published_at`, `source`, `lang`). Дедупликация по URL и хэшу текста. Проверить баланс кредитов Apify до старта.
- 6. Jev.** Вход: статья + профиль сущности (название, страна, отрасль, ключевые люди). Выход JSON: `relevant`, `entity_match` (`same` / `different` / `unsure`), `category`, `stage`, `confidence`. Каскад: сначала локальная модель; если

`confidence` ниже порога, повтор в облаке (статья публичная, это разрешено).

7. **Контракты.** JSON для `findings`, `score`, `assessment` согласовать в первый час. Фронтенд работает на моках до готовности бэкенда.

`entity_match` — главное поле Jev. Самая частая ошибка adverse media скрининга — чужие новости об одноимённой компании. Леонид размечает около 50 статей (релевантна / одноимённая / не про риск), чтобы измерить точность Jev цифрой, а не на глаз.

F1. Репутационный риск компании и её связей

F1 — главная фишка демо. Она отвечает на вопрос «насколько рискованна компания и её окружение» баллом 0–10 с аргументами, где каждый аргумент ведёт к цитате.

Вход: название и страна, опционально LEI или номер KRS.

1. **Карточка сущности.** Название, варианты написания, страна, отрасль. Идентификаторы из открытых реестров: GLEIF (LEI и материнские компании), для Польши — KRS (правление, владельцы). Доступ к обоим API проверить в первый час. Не работает — связи вводятся вручную.
2. **Связи.** Материнская компания, дочерние, ключевые лица (руководство, бенефициары). В MVP глубина 1.
3. **Санкции и PEP.** Скрининг по открытому датасету (OpenSanctions; лицензию проверить, бесплатен для некоммерческого использования). Точное совпадение — флаг. Нечёткое — «требуется проверки», решает человек.
4. **Новости.** Для каждой сущности: Apify → Jev → релевантные статьи.
5. **Извлечение фактов** (облако, только публичные статьи): категория (коррупция, мошенничество, санкции, экология, трудовые права, суды, спорная продукция), стадия (обвинение, расследование, обвинительный акт, приговор или мировое соглашение, оправдание), дата, источник, точная цитата.
6. **Склейка событий.** Десять статей об одном событии — одно событие. Перепечатки не считаются независимыми подтверждениями.
7. **Проверка цитат.** Цитата должна дословно найтись в тексте статьи. Факт без найденной цитаты отбрасывается.
8. **Балл** по матрице (раздел ниже) для компании и для каждой связи. Риск связей добавляет до 1 балла компании.
9. **Экран.** Балл и полоса (low / medium / high), разложение по компонентам, под каждым — факты с цитатами и ссылками, связи с цветом риска, отдельно — отброшенные статьи об одноимённых компаниях.

Модели: облако для статей; локально, если связи пришли из внутреннего досье клиента.

Готово, когда: у демо-компании есть балл, минимум три факта с цитатами, одна связь со своим баллом, и одноимённая компания видна как отсеянная.

Не делаем: глубину связей больше 1, автоматическое распутывание сложных структур владения.

F2. Мониторинг и защита репутации

F2 — это цепочка F1, запущенная по расписанию. Она следит за банком и его клиентами и поднимает тревогу, когда новая публикация меняет картину риска.

1. **Watch-list.** Сам банк, клиенты из портфеля (синтетические), темы риска.
2. **Расписание.** Worker раз в N минут запускает акторы Apify по watch-list. Частоту ограничить кредитами Apify; бюджет проверяется до запуска.
3. **Новое или старое.** Jev → извлечение фактов → сравнение с известными событиями: новое событие или продолжение уже учтённого.
4. **Скорость.** Публикации об одном событии группируются; число публикаций за окно времени — сигнал того, что история разгоняется.
5. **Пересчёт.** Новое событие пересчитывает балл клиента. Алерт — при переходе полосы (например, medium → high) или при событии максимальной тяжести.
6. **Алерт.** Карточка в ленте с причиной. Опционально Telegram, только шаблон: имя, новый балл, ссылка, без внутренних данных.
7. **Replay для демо.** Заранее собранные статьи подаются в тот же пайплайн с ускорением. Помечены как demo.

Модели: Jev каскадом, извлечение — облако.

Готово, когда: статья из replay меняет балл клиента и создаёт алерт с понятной причиной.

Не делаем: мониторинг всего интернета, живой опрос Apify во время показа.

F3. Ответ на текущий скандал

F3 нужен компании, у которой скандал прямо сейчас. Он разбирает утверждения, находит, что их подтверждает и что опровергает, и готовит контрпозицию. Это ядро прошлого плана v2, код переиспользуется.

1. **Вход.** Событие из F2 или ссылка и текст публикации.
2. **Утверждения.** До трёх конкретных проверяемых утверждений.
3. **Доказательства.** Внешние публикации: подтверждают или опровергают, независимые или перепечатки. Внутренние документы компании — только через локальную модель.
4. **Вердикт по каждому утверждению:** подтверждается, противоречит документам, недостаточно данных, мнение.
5. **Контраргументы только с доказательствами.** Если опровержения нет, система так и пишет. Искать «аргументы против» ради баланса запрещено: это превращает инструмент в генератор оправданий.
6. **Черновик контрпозиции.** Признать подтверждённое, уточнить масштаб, опровергнуть с цитатами то, что опровергается. Внутренние факты попадают в публичный текст только после подтверждения владельцем данных (роль `compliance`).
7. **Утверждение человеком.** Правка после подтверждения снимает его.

Модели: внешние статьи — облако; внутренние документы и черновик, который на них опирается, — локально.

Готово, когда: одно событие даёт два утверждения с разными вердиктами и черновик, где каждое утверждение со ссылкой.

Приоритет: P1. Делать только после работающих F1, F4, F5.

F4. Policy navigator

F4 сопоставляет клиента с политикой банка и показывает, при каких условиях онбординг ей соответствует. Он не ищет, как обойти политику: жёсткие запреты остаются запретами, а условия берутся только из текста самой политики. На сцене формулировка «обойти policy» снимет проект с оценки, а «найти соответствующий политике путь для клиента высокого риска» — это стандартный risk-based approach.

1. **Политика.** Синтетическая, 12–20 пунктов, по мотивам публичных политик банков для оборонного и других чувствительных секторов. Пишет Леонид, пересказом, без копирования чужого текста.
2. **Разметка пунктов** — вручную, как данные, в первые часы. Для каждого пункта:
 - `type: hard_exclusion / conditional / discretionary`;
 - условие срабатывания;

- что требуется: углублённая проверка (EDD), одобрение уровня X, ограничения по продуктам, мониторинг;
 - цитата пункта. Двадцать пунктов размечаются руками за час; разметка политики моделью на сцене — лишний риск.
3. **Сопоставление.** Факты клиента (результаты F1 + KYC-досье, локально) → сработавшие пункты, у каждого — факт, который его вызвал.
 4. **Итог.** `Prohibited` (сработал жёсткий запрет), `Eligible with conditions` (список условий из политики с цитатами), `Eligible`.
 5. **Обоснование для риск-комитета.** Черновик, локальная модель.
 6. **Красные линии в коде.** Жёсткий запрет или подтверждённое санкционное совпадение → `Prohibited` независимо от того, что ответила модель. Система никогда не предлагает переформулировать факты, скрыть информацию или разделить отношения, чтобы не попасть под порог.

Пример для демо: оборонный поставщик. Пункт «не финансируем компании, производящие запрещённые виды оружия» — жёсткий запрет. Пункт «оборонный сектор допускается при подтверждённом соблюдении экспортного контроля, углублённой проверке и одобрении старшего уровня» — условный. Два демо-клиента дают разные итоги: один `Prohibited`, второй `Eligible with conditions`.

Модели: только локальная. Политика и досье — конфиденциальны.

Готово, когда: два клиента дают разные итоги, и у каждого сработавшего пункта видны цитата политики и факт-триггер.

F5. Ассистент аналитика и бриф для руководства

F5 собирает результаты F1–F4 в одностраничный бриф для руководства и отвечает на вопросы аналитика только по уже собранным данным.

1. **Шаблон брифа:** резюме (балл, полоса, итог по политике), ключевые факты с цитатами, связи, условия онбординга, открытые вопросы, дата среза данных.
2. **Генерация по секциям.** Секции на публичных фактах могут идти в облако; секции с досье клиента и политикой — локально. Решает роутер по меткам данных, а не разработчик в коде фичи.
3. **Вопросы аналитика.** «Почему балл 7?», «какие факты старше пяти лет?». Ответ только из `findings` и `assessments`, со ссылками. Вопрос вне собранных данных → «нет данных», без похода в интернет.
4. **Экспорт в PDF.**

5. Подпись аналитика. Бриф получает статус reviewed; правка после подписи снимает её.

Готово, когда: бриф по демо-компании собирается одной кнопкой, и каждый факт в нём кликается до источника.

Не делаем: свободный чат-бот по интернету. Это делает продукт обычным wrapper и ломает правило «только из собранных данных».

Матрица риска 0-10

Балл считает код по явным критериям; LLM только извлекает факты. Веса ниже — демо-настройка, а не откалиброванная модель: в банке её заменяет собственная матрица, поэтому храним её в YAML.

Компонент	Как считается	Баллы
Санкции	Подтверждённое совпадение по реестру с идентификатором	Сразу 10 и Prohibited, остальное не считается
Негативные публикации	Сумма по событиям: тяжесть × стадия × давность × достоверность, каждое событие до 1	0-3
Юрисдикция	Страна в списках повышенного риска FATF	0-2
Сектор	Чувствительная отрасль по политике банка	0-2
PEP	Политически значимые лица среди владельцев и руководства	0-1
Прозрачность владения	Неизвестный бенефициар, сложная структура	0-1
Риск связей	Максимальный балл связанных лиц, приведённый к 0-1	0-1

Полосы: 0-3.9 low, 4-6.9 medium, 7-10 high.

Множители для события:

- **Тяжесть:** коррупция, санкции, мошенничество — 1.0; экология, трудовые права — 0.7; прочие суды — 0.5; репутационные споры — 0.3.
- **Стадия:** обвинение в СМИ — 0.3; расследование — 0.5; обвинительный акт — 0.7; приговор или мировое соглашение — 1.0; оправдание — 0.
- **Давность:** до 2 лет — 1.0; 2-5 лет — 0.6; старше 5 лет — 0.3.
- **Достоверность источника:** суд или регулятор — 1.0; крупное СМИ — 0.8; прочие — 0.4; соцсети — 0.2.

Аргументы «почему такой балл» — это разложение, а не текст модели: под каждым компонентом факты, которые его дали, с цитатами, и формула по клику. Отдельный блок «почему не выше» — что отброшено: оправдания, одноимённые компании, перепечатки. Модель может пересказать это человеческим языком, но число в пересказе берётся из расчёта, а не генерируется.

AI Control Layer для трека Goldman

Для Goldman продукт — пример того, как дать ИИ доступ к клиентским данным и к интернету, не потеряв контроль. Слой контроля должен быть виден на экране, иначе жюри увидит просто KYC-инструмент.

- **Метки данных.** `public` / `confidential` / `restricted` на каждой записи. Роутер запрещает конфиденциальное в облако кодом.
- **Недоверенный контент.** Статьи — данные, а не инструкции. У моделей, которые читают статьи (Jev, извлечение фактов), нет инструментов с побочными эффектами: они только возвращают JSON.
- **Красные линии как код.** Жёсткие запреты политики и санкционное правило работают без LLM.
- **Бюджеты.** Лимит запусков Apify и вызовов LLM на одну проверку, проверяется до вызова.
- **Журнал.** Каждый вызов модели (модель, метка данных, решение роутера), каждый запуск Apify, каждое решение человека.
- **Подпись человека** на брифе и решении по клиенту.
- **Экран Control log** с фильтрами по проверке, модели, метке.
- **Тесты роутера без ключей API.** Детерминированные, запускаются за секунду. Это главный ответ на «GPT wrapper».
- **Сильный демо-момент:** выключить интернет — проверка по досье и политике продолжает работать на локальной модели.

Честная граница: в демо Supabase облачный и хранит синтетику. В проде он self-hosted внутри периметра банка.


Если подаёте и в Рекао: F2 и F3 — это устойчивость банка к информационным атакам; подача строится вокруг них.

Порядок сборки и роли

Сначала то, без чего нет демо: F0, затем F1 и F4 параллельно, F5 поверх них. F2 и F3 начинаются только после первого полного прогона на хостинге.

Ядро F1 и F4 до вечера, F2 и F3 только после полного прогона в 22:00

Суббота 11:00 → воскресенье 11:00, местное время



план на 24 часа · фичи и контрольные точки

Время фич ориентировочное; контрольные точки (прогон в 22:00, freeze в 07:00, сдача в 10:30) не сдвигаются.

Кто	Зона	Фичи
Backend 1	Supabase, API, роутер моделей, журнал, ингест Apify, worker и расписание	F0, F2
Backend 2	Јев, извлечение фактов, проверка цитат, матрица, сопоставление с политикой, генерация брифа	F1, F4, F5
Frontend 1	Каркас, экран компании (балл, компоненты, факты, связи), алерты, Control log	F1, F2, слой контроля

Кто	Зона	Фичи
Frontend 2	Экран policy navigator, бриф и экспорт, экран скандала	F4, F5, F3
Леонид	Политика на 20 пунктов и её разметка, KYC-досье, синтетические статьи, разметка 50 статей для Jev, менторы, питч и подача	Данные, питч

Правила отсечения:

- **14:00** — Jev не работает локально → весь Jev в облако (статьи публичные), локальная модель только для F4 и F5.
- **19:00** — нет балла с цитатами по демо-компании → все на F1, F4 упрощается до жёстких запретов.
- **22:00** — нет полного прогона на хостинге → F2 и F3 вырезаны.
- **07:00** — feature freeze, дальше только баги, видео и подача.
- **10:30** — сдача, не в последнюю минуту.

Решить до 11:30: что такое Jev; какие 2–3 актора Arify; какая локальная модель и её скорость; можно ли подать в две категории; разрешён ли код до старта.

Демо, риски и что режем

Демо идёт на вымышленном клиенте с синтетическими статьями и досье, плюс один короткий живой прогон Arify по реальной компании, чтобы доказать, что пайплайн работает на настоящих данных. Вымышленную компанию реальные источники не упомянут, а внутреннее досье о реальной компании на сцене выдумывать нельзя.

Сценарий на 3 минуты:

1. **0:00** — проблема: аналитики тратят часы на ручную проверку, а данные клиента нельзя отправить в публичный ИИ.
2. **0:20** — F1 по клиенту: балл, компоненты, факты с цитатами, связь с повышенным риском, отсеянная одноимённая компания.
3. **1:00** — F4: Eligible with conditions с цитатами пунктов; второй клиент — Prohibited по красной линии в коде.
4. **1:40** — F5: бриф одной кнопкой. Control log показывает, что конфиденциальные шаги шли только на локальную модель. Выключаем интернет — проверка по досье работает.
5. **2:20** — F2: статья из replay поднимает балл и создаёт алерт.

6. 2:45 — живой Arify по реальной компании: только найденные публикации, без балла и без вердикта.

Риск	Что делаем
Актеры Arify возвращают разные форматы, падают, тратят кредиты	Нормализация в один формат, кэш, replay на сцене
Скрейперы соцсетей (X, LinkedIn) нарушают правила платформ	Не выносить в питч; сказать, что в проде — лицензированные потоки данных
Локальная модель медленная или слабая	Замер в первый час; локально только F4 и конфиденциальные части F5; демо на самом мощном ноутбуке
Ев путает одноимённые компании	Поле <code>entity_match</code> , идентификаторы из реестров, точность на размеченных 50 статьях
Модель выдумывает факты	Цитата должна дословно найтись в статье, иначе факт отбрасывается
Реальные компании на сцене	Только факты, подтверждённые судом или регулятором; без балла и вердикта
F4 воспринимается как «обход политики»	Формулировка, красные линии в коде, условия только из текста политики
Пять фич за 24 часа	Порядок сборки и правила отсечения ниже

Порядок сокращения: F3 → живой Arify в F2 (оставить replay) → вопросы аналитика в F5 (оставить бриф) → экспорт PDF → связи компании.

Не сокращается: балл F1 с цитатами, красные линии F4, роутер с журналом, тесты роутера.